



## 法律声明

本课件包括演示文稿、示例、代码、题库、视频和声音等内容，深度之眼和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

### 课程详情请咨询

- 微信公众号：深度之眼
- 客服微信号：deepshare0920



公众号



微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料





deepshare.net

深度之眼

# 西瓜书公式推导

导师: Sm1les (Datawhale南瓜书项目负责人)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 对数几率回归公式推导

Derivation of Logistic Regression

---



# 本节大纲

Outline

---



deepshare.net

深度之眼

先修内容：西瓜书3.3

1. 广义线性模型

2. 对数几率回归

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 广义线性模型

Generalized Linear Model

---



deepshare.net

深度之眼

1. 指数族分布

2. 广义线性模型的三条假设

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 广义线性模型

Generalized Linear Model



deepshare.net

深度之眼

指数族分布：

指数族（Exponential family）分布是一类分布的总称，该类分布的分布律（或者概率密度函数）的一般形式如下：

$$p(y; \eta) = b(y) \exp(\eta^T T(y) - a(\eta))$$

其中， $\eta$  称为该分布的自然参数； $T(y)$  为充分统计量，视具体的分布而定，通常是等于随机变量 $y$ 本身； $a(\eta)$  为配分函数； $b(y)$  为关于随机变量 $y$ 的函数，常见的伯努利分布和正态分布均属于指数族分布。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 广义线性模型



Generalized Linear Model 关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

证明伯努利分布属于指数族分布：

已知伯努利分布的分布律为：

$$p(y) = \phi^y (1 - \phi)^{1-y}$$

其中  $y \in \{0, 1\}$ ， $\phi$  为  $y = 1$  的概率，即  $p(y = 1) = \phi$ 。对上式恒等变形可得：

$$\begin{aligned} p(y) &= \phi^y (1 - \phi)^{1-y} \\ &= \exp \left( \ln \left( \phi^y (1 - \phi)^{1-y} \right) \right) \\ &= \exp \left( \ln \phi^y + \ln(1 - \phi)^{1-y} \right) \end{aligned}$$

# 广义线性模型

Generalized Linear Model



deepshare.net

深度之眼

$$\begin{aligned} p(y) &= \exp(y \ln \phi + (1 - y) \ln(1 - \phi)) \\ &= \exp(y \ln \phi + \ln(1 - \phi) - y \ln(1 - \phi)) \\ &= \exp(y (\ln \phi - \ln(1 - \phi)) + \ln(1 - \phi)) \\ &= \exp\left(y \ln \left(\frac{\phi}{1 - \phi}\right) + \ln(1 - \phi)\right) \end{aligned}$$

对比指数族分布的一般形式  $p(y; \eta) = b(y) \exp(\eta^T T(y) - a(\eta))$  可知：

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 广义线性模型

Generalized Linear Model



deepshare.net

深度之眼

伯努利分布的指数族分布对应参数为：

$$b(y) = 1$$

$$\eta = \ln \left( \frac{\phi}{1 - \phi} \right)$$

$$T(y) = y$$

$$a(\eta) = -\ln(1 - \phi) = \ln(1 + e^\eta)$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 广义线性模型

Generalized Linear Model



deepshare.net

深度之眼

广义线性模型的三条假设：

1. 在给定  $\boldsymbol{x}$  的条件下，假设随机变量  $y$  服从某个指数族分布；
2. 在给定  $\boldsymbol{x}$  的条件下，我们的目标是得到一个模型  $h(\boldsymbol{x})$  能预测出  $T(y)$  的期望值；
3. 假设该指数族分布中的自然参数  $\eta$  和  $\boldsymbol{x}$  呈线性关系，即  $\eta = \boldsymbol{w}^T \boldsymbol{x}$

参考文献：Andrew Ng. cs229-notes1

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression

---



deepshare.net

深度之眼

1.对数几率回归的广义线性模型推导

2.极大似然估计法

3.对数几率回归的参数估计

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 对数几率回归

Logistic Regression

---



deepshare.net

深度之眼

对数几率回归是在对一个二分类问题进行建模，并且假设被建模的随机变量 $y$ 取值为0或1，因此我们可以很自然地假设 $y$ 服从伯努利分布。此时，如果我们想要构建一个线性模型来预测在给定  $\boldsymbol{x}$  的条件下 $y$ 的取值的话，可以考虑使用广义线性模型来进行建模。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

已知 $y$ 是服从伯努利分布，而伯努利分布属于指数族分布，所以满足广义线性模型的第一条假设，接着根据广义线性模型的第二条假设我们可以推得模型  $h(\mathbf{x})$  的表达式为：

$$h(\mathbf{x}) = E[T(y|\mathbf{x})]$$

由于伯努利分布的  $T(y|\mathbf{x}) = y|\mathbf{x}$  所以：

$$h(\mathbf{x}) = E[y|\mathbf{x}]$$

又因为  $E[y|\mathbf{x}] = 1 \times p(y = 1|\mathbf{x}) + 0 \times p(y = 0|\mathbf{x}) = p(y = 1|\mathbf{x}) = \phi$  所以：

$$h(\mathbf{x}) = \phi$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

在前面证明伯努利分布属于指数族分布时我们知道：

$$\eta = \ln \left( \frac{\phi}{1 - \phi} \right)$$

$$e^{\eta} = \frac{\phi}{1 - \phi}$$

$$e^{-\eta} = \frac{1 - \phi}{\phi}$$

$$e^{-\eta} = \frac{1}{\phi} - 1$$

$$1 + e^{-\eta} = \frac{1}{\phi}$$

$$\frac{1}{1 + e^{-\eta}} = \phi$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

将  $\phi = \frac{1}{1 + e^{-\eta}}$  代入  $h(\mathbf{x})$  的表达式可得：

$$h(\mathbf{x}) = \phi = \frac{1}{1 + e^{-\eta}}$$

根据广义模型的第三条假设： $\eta = \mathbf{w}^T \mathbf{x}$ ， $h(\mathbf{x})$  最终可化为：

$$h(\mathbf{x}) = \phi = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = p(y = 1 | \mathbf{x}) \quad \text{此即为式3.23}$$

此即为对数几率回归模型。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



极大似然估计法：

设总体的概率密度函数（或分布律）为  $f(y, w_1, w_2, \dots, w_k)$ ， $y_1, y_2, \dots, y_m$  为从该总体中抽出的样本。因为  $y_1, y_2, \dots, y_m$  相互独立且同分布，于是，它们的联合概率密度函数（或联合概率）为

$$L(y_1, y_2, \dots, y_m; w_1, w_2, \dots, w_k) = \prod_{i=1}^m f(y_i, w_1, w_2, \dots, w_k)$$

其中， $w_1, w_2, \dots, w_k$  被看作固定但是未知的参数。当我们已经观测到一组样本观测值  $y_1, y_2, \dots, y_m$  时，要去估计未知参数，一种直观的想法就是，哪一组参数值使得现在的样本观测值出现的概率最大，哪一组参数可能就是真正的参数，我们就用它作为参数的估计值，这就是所谓的极大似然估计。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

极大似然估计的具体方法：

通常记  $L(y_1, y_2, \dots, y_m; w_1, w_2, \dots, w_k) = L(\mathbf{w})$ ，并称其为似然函数。于是求  $\mathbf{w}$  的极大似然估计就归结为求  $L(\mathbf{w})$  的最大值点。由于对数函数是单调递增函数，所以

$$\ln L(\mathbf{w}) = \ln \left( \prod_{i=1}^m f(y_i, w_1, w_2, \dots, w_k) \right) = \sum_{i=1}^m \ln f(y_i, w_1, w_2, \dots, w_k)$$

与  $L(\mathbf{w})$  有相同的最大值点，而在许多情况下，求  $\ln L(\mathbf{w})$  的最大值点比较简单，于是，我们就将求  $L(\mathbf{w})$  的最大值点转化为了求  $\ln L(\mathbf{w})$  的最大值点，通常称  $\ln L(\mathbf{w})$  为对数似然函数。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

对数几率回归的极大似然估计：

已知随机变量 $y$ 取1和0的概率分别为

$$p(y = 1|x) = \frac{e^{\mathbf{w}^T \mathbf{x} + b}}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

$$p(y = 0|x) = \frac{1}{1 + e^{\mathbf{w}^T \mathbf{x} + b}}$$

令  $\boldsymbol{\beta} = (\mathbf{w}; b)$ ,  $\hat{\mathbf{x}} = (\mathbf{x}; 1)$ , 则  $\mathbf{w}^T \mathbf{x} + b$  可简写为  $\boldsymbol{\beta}^T \hat{\mathbf{x}}$ , 于是上式可化简为

$$p(y = 1|x) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}$$

$$p(y = 0|x) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

记

$$p(y = 1|\mathbf{x}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

$$p(y = 0|\mathbf{x}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}}} = p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$$

于是，使用一个小技巧即可得到随机变量 $y$ 的分布律表达式

$$p(y|\mathbf{x}; \mathbf{w}, b) = y \cdot p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) + (1 - y) \cdot p_0(\hat{\mathbf{x}}; \boldsymbol{\beta}) \quad \text{此即为式3.26}$$

或者

$$p(y|\mathbf{x}; \mathbf{w}, b) = [p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})]^y [p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})]^{1-y}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

根据对数似然函数的定义可知

$$\ln L(\mathbf{w}) = \sum_{i=1}^m \ln f(y_i, w_1, w_2, \dots, w_k)$$

由于此时的 $y$ 为离散型，所以将对数似然函数中的概率密度函数换成分布律即可

$$\ell(\mathbf{w}, b) := \ln L(\mathbf{w}, b) = \sum_{i=1}^m \ln p(y_i | \mathbf{x}_i; \mathbf{w}, b) \quad \text{此即为式3.25}$$

将  $p(y | \mathbf{x}; \mathbf{w}, b) = y \cdot p_1(\hat{\mathbf{x}}; \boldsymbol{\beta}) + (1 - y) \cdot p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})$  代入对数似然函数可得：

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^m \ln (y_i p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) + (1 - y_i) p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

由于  $p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$  ,  $p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}) = \frac{1}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}$  所以上式可化为

$$\begin{aligned}\ell(\boldsymbol{\beta}) &= \sum_{i=1}^m \ln \left( \frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} + \frac{1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \ln \left( \frac{y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i}{1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}} \right) \\ &= \sum_{i=1}^m \left( \ln(y_i e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i} + 1 - y_i) - \ln(1 + e^{\boldsymbol{\beta}^T \hat{\mathbf{x}}_i}) \right)\end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

由于  $y_i \in \{0, 1\}$ ，所以

当  $y_i = 0$  时：

$$\ell(\beta) = \sum_{i=1}^m \left( \ln(0 \cdot e^{\beta^T \hat{x}_i} + 1 - 0) - \ln(1 + e^{\beta^T \hat{x}_i}) \right) = \sum_{i=1}^m \left( \ln 1 - \ln(1 + e^{\beta^T \hat{x}_i}) \right) = \sum_{i=1}^m \left( -\ln(1 + e^{\beta^T \hat{x}_i}) \right)$$

当  $y_i = 1$  时：

$$\ell(\beta) = \sum_{i=1}^m \left( \ln(1 \cdot e^{\beta^T \hat{x}_i} + 1 - 1) - \ln(1 + e^{\beta^T \hat{x}_i}) \right) = \sum_{i=1}^m \left( \ln e^{\beta^T \hat{x}_i} - \ln(1 + e^{\beta^T \hat{x}_i}) \right) = \sum_{i=1}^m \left( \beta^T \hat{x}_i - \ln(1 + e^{\beta^T \hat{x}_i}) \right)$$

综合可得

$$\ell(\beta) = \sum_{i=1}^m \left( y_i \beta^T \hat{x}_i - \ln(1 + e^{\beta^T \hat{x}_i}) \right) \quad \text{加个负号即为式3.27}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

若  $p(y|\mathbf{x}; \mathbf{w}, b) = [p_1(\hat{\mathbf{x}}; \boldsymbol{\beta})]^y [p_0(\hat{\mathbf{x}}; \boldsymbol{\beta})]^{1-y}$  , 将其代入对数似然函数可得

$$\begin{aligned}\ell(\boldsymbol{\beta}) &= \sum_{i=1}^m \ln ([p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta})]^{y_i} [p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})]^{1-y_i}) \\&= \sum_{i=1}^m [\ln ([p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta})]^{y_i}) + \ln ([p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta})]^{1-y_i})] \\&= \sum_{i=1}^m [y_i \ln (p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta})) + (1 - y_i) \ln (p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))] \\&= \sum_{i=1}^m \{y_i [\ln (p_1(\hat{\mathbf{x}}_i; \boldsymbol{\beta})) - \ln (p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))] + \ln (p_0(\hat{\mathbf{x}}_i; \boldsymbol{\beta}))\}\end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# 对数几率回归

Logistic Regression



deepshare.net

深度之眼

$$\ell(\beta) = \sum_{i=1}^m \left[ y_i \ln \left( \frac{p_1(\hat{\mathbf{x}}_i; \beta)}{p_0(\hat{\mathbf{x}}_i; \beta)} \right) + \ln(p_0(\hat{\mathbf{x}}_i; \beta)) \right]$$

由于  $p_1(\hat{\mathbf{x}}_i; \beta) = \frac{e^{\beta^T \hat{\mathbf{x}}_i}}{1 + e^{\beta^T \hat{\mathbf{x}}_i}}$  ,  $p_0(\hat{\mathbf{x}}_i; \beta) = \frac{1}{1 + e^{\beta^T \hat{\mathbf{x}}_i}}$  所以上式可化为

$$\ell(\beta) = \sum_{i=1}^m \left[ y_i \ln \left( e^{\beta^T \hat{\mathbf{x}}_i} \right) + \ln \left( \frac{1}{1 + e^{\beta^T \hat{\mathbf{x}}_i}} \right) \right]$$

$$= \sum_{i=1}^m \left( y_i \beta^T \hat{\mathbf{x}}_i - \ln(1 + e^{\beta^T \hat{\mathbf{x}}_i}) \right) \quad \text{加个负号即为式3.27}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

# —— 结 语 ——

在这次课程中，我们学习了西瓜书

对数几率回归的公式推导

那么在下次课程中，我们将会学习西瓜书

**决策树的公式推导**



关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料





**deepshare.net**

深度之眼

联系我们：

电话：18001992849

邮箱：[service@deepshare.net](mailto:service@deepshare.net)

QQ：2677693114



公众号



客服微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料