



法律声明

本课件包括演示文稿、示例、代码、题库、视频和声音等内容，深度之眼和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

课程详情请咨询

- 微信公众号：深度之眼
- 客服微信号：deepshare0920



公众号



微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

西瓜书公式推导

导师: Sm1les (Datawhale南瓜书项目负责人)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

软间隔与支持向量回归 公式推导

Derivation of soft margin and SVR

本节大纲

Outline



先修内容：西瓜书6.4、6.5

1. 软间隔SVM

2. 支持向量回归

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

软间隔SVM

Soft margin SVM

严格线性可分时的硬间隔SVM:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.t.} \quad & 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b) \leq 0, \quad i = 1, 2, \dots, m \end{aligned}$$

然而实际场景中，严格线性可分的数据并不总是存在，那么就需要适当放松约束条件。软间隔SVM允许某些样本不满足函数间隔值大于等于1这个约束，也即允许函数间隔值小于1，当然，这样的样本尽量越少越好，因此优化问题可以改写为

线性不可分时的软间隔SVM:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \ell_{0/1} (y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1)$$

其中

$$\ell_{0/1}(z) = \begin{cases} 0, & \text{if } z \geq 0 \\ 1, & \text{otherwise} \end{cases}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

软间隔SVM

Soft margin SVM

由于 $\ell_{0/1}$ 非凸、不连续，数学性质不太好，不易优化求解，因此需要考虑用其他损失函数来近似替代 $\ell_{0/1}$ 软间隔SVM选的替代损失函数是合页（hinge）损失函数

$$\ell_{\text{hinge}}(z) = \max(0, 1 - z)$$

合页损失可以理解为：待考察变量 z 如果大于等于1就不惩罚，但是如果小于1就需要惩罚，但是惩罚的程度取决于自身比1小的程度，显然合页损失很适合用来考察软间隔SVM里面的函数间隔值。

软间隔SVM

Soft margin SVM



deepshare.net

深度之眼

将优化问题中的 $\ell_{0/1}$ 损失函数更换为合页损失函数可得

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \max(0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b))$$

为了引入松弛因子，令

$$\max(0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)) = \xi_i$$

则上述优化问题即可改写为

$$\min_{\mathbf{w}, b, \xi_i} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$\text{s.t. } y_i (\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i$$

$$\xi_i \geq 0, i = 1, 2, \dots, m$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

支持向量回归



SVR

SVR和SVM唯一的联系就是优化目标函数很相像，但是其建模思路差别很大。SVR实际就是找一个以 $f(\boldsymbol{x})$ 为中心，宽度为 2ϵ 的间隔带，使得此间隔带尽可能多地把所有样本都包裹住。

由外到内的思路：假设这条间隔带能包裹住所有样本，那么有两种方式可以做到，一种是 ϵ 取任意大，那么以任意 $f(\boldsymbol{x})$ 为中心的间隔带都能把所有样本包裹住，但是显然这样是没有意义的。另一种就是找尽可能小的 ϵ 使得其能把所有样本包裹住，那么能把所有样本包裹住的间隔带的 ϵ 最小是多少呢？可以通过以下优化问题来求解

$$\begin{aligned} \min_{\boldsymbol{w}, b, \epsilon} \quad & \epsilon \\ \text{s.t.} \quad & -\epsilon \leq y_i - f(\boldsymbol{x}_i) \leq \epsilon \end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

支持向量回归

SVR

但是由于实际采样得到的样本会存在极个别偏离大多数样本很远的噪音，那么此时如果按照以上优化目标来进行求解的话也会导致 ϵ 偏大，因此，通常都会考虑人为固定 ϵ 的取值。显然，一旦固定 ϵ 后上述优化问题就会无法求解，因此需要给两边添加松弛因子

$$\begin{aligned} \min_{w, b, \xi, \hat{\xi}} \quad & \epsilon + \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & -\epsilon - \xi_i \leq y_i - f(\mathbf{x}_i) \leq \epsilon + \hat{\xi}_i \\ & \xi_i \geq 0 \\ & \hat{\xi}_i \geq 0 \end{aligned}$$

$$\begin{aligned} \min_{w, b, \xi, \hat{\xi}} \quad & \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & -\epsilon - \xi_i \leq y_i - f(\mathbf{x}_i) \leq \epsilon + \hat{\xi}_i \\ & \xi_i \geq 0 \\ & \hat{\xi}_i \geq 0 \end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

支持向量回归

SVR

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

为了和SVM的优化问题保持形式一致，从而方便继承SVM自带的一套东西，可以考虑加一个L2正则项，也即

$$\begin{aligned} \min_{\mathbf{w}, b, \xi, \hat{\xi}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & -\epsilon - \xi_i \leq y_i - f(\mathbf{x}_i) \leq \epsilon + \hat{\xi}_i \\ & \xi_i \geq 0 \\ & \hat{\xi}_i \geq 0 \end{aligned}$$

通常还会考虑给松弛因子添加一个正则化常数C，同时约束条件也可以进行恒等变形，进而也就得到了常见的SVR优化问题

$$\begin{aligned} \min_{\mathbf{w}, b, \xi, \hat{\xi}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i) \\ \text{s.t.} \quad & y_i - f(\mathbf{x}_i) \leq \epsilon + \hat{\xi}_i \\ & f(\mathbf{x}_i) - y_i \leq \epsilon + \xi_i \\ & \xi_i \geq 0 \\ & \hat{\xi}_i \geq 0 \end{aligned}$$

此即为式6.45

—— 结 语 ——

在这次课程中，我们学习了西瓜书
软间隔与支持向量回归的公式推导

那么在下次课程中，我们将会学习西瓜书

朴素贝叶斯



关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

联系我们：

电话：18001992849

邮箱：service@deepshare.net

QQ：2677693114



公众号



客服微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料