



法律声明

本课件包括演示文稿、示例、代码、题库、视频和声音等内容，深度之眼和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

课程详情请咨询

- 微信公众号：深度之眼
- 客服微信号：deepshare0920



公众号



微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

西瓜书公式推导

导师: Sm1les (Datawhale南瓜书项目负责人)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯公式推导

Derivation of Naive Bayes formula

本节大纲

Outline



deepshare.net

深度之眼

先修内容：西瓜书7.1、7.2、7.3

1. 贝叶斯判定准则

2. 多元正态分布参数的极大似然估计

3. 朴素贝叶斯分类器

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

贝叶斯判定准则

Bayes Decision Rule



deepshare.net

深度之眼

贝叶斯判定准则：

为最小化总体风险，只需在每个样本上选择那个能使条件风险 $R(c|\mathbf{x})$ 最小的类别标记，即

$$h^*(\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} R(c|\mathbf{x})$$

此时， h^* 称为贝叶斯最优分类器。

贝叶斯判定准则

Bayes Decision Rule



deepshare.net

深度之眼

已知条件风险 $R(c|\mathbf{x})$ 的计算公式为

$$R(c_i|\mathbf{x}) = \sum_{j=1}^N \lambda_{ij} P(c_j|\mathbf{x}) \quad \text{书上式7.1}$$

若目标是最小化分类错误率，则误判损失 λ_{ij} 对应为0/1损失，也即

$$\lambda_{ij} = \begin{cases} 0, & \text{if } i = j \\ 1, & \text{otherwise} \end{cases}$$

那么条件风险 $R(c|\mathbf{x})$ 的计算公式可以进一步展开为

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

贝叶斯判定准则



Bayes Decision Rule

$$\begin{aligned} R(c_i|\mathbf{x}) &= 1 \times P(c_1|\mathbf{x}) + \dots + 1 \times P(c_{i-1}|\mathbf{x}) + 0 \times P(c_i|\mathbf{x}) + 1 \times P(c_{i+1}|\mathbf{x}) + \dots + 1 \times P(c_N|\mathbf{x}) \\ &= P(c_1|\mathbf{x}) + \dots + P(c_{i-1}|\mathbf{x}) + P(c_{i+1}|\mathbf{x}) + \dots + P(c_N|\mathbf{x}) \end{aligned}$$

由于 $\sum_{j=1}^N P(c_j|\mathbf{x}) = 1$, 所以

$$R(c_i|\mathbf{x}) = 1 - P(c_i|\mathbf{x}) \quad \text{此即为式7.5}$$

于是, 最小化错误率的贝叶斯最优分类器为

$$h^*(\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} R(c|\mathbf{x}) = \arg \min_{c \in \mathcal{Y}} (1 - P(c|\mathbf{x})) = \arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x})$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

已知对数似然函数为

$$LL(\boldsymbol{\theta}_c) = \sum_{\boldsymbol{x} \in D_c} \log P(\boldsymbol{x} | \boldsymbol{\theta}_c) \quad \text{书上式7.10}$$

为了便于后续计算，我们令log的底数为e，则对数似然函数可化为

$$LL(\boldsymbol{\theta}_c) = \sum_{\boldsymbol{x} \in D_c} \ln P(\boldsymbol{x} | \boldsymbol{\theta}_c)$$

由于 $P(\boldsymbol{x} | \boldsymbol{\theta}_c) = P(\boldsymbol{x} | c) \sim \mathcal{N}(\boldsymbol{\mu}_c, \boldsymbol{\sigma}_c^2)$ ，那么

$$P(\boldsymbol{x} | \boldsymbol{\theta}_c) = \frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}_c|}} \exp\left(-\frac{1}{2}(\boldsymbol{x} - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1}(\boldsymbol{x} - \boldsymbol{\mu}_c)\right)$$

其中，d表示 \boldsymbol{x} 的维数， $\boldsymbol{\Sigma}_c = \boldsymbol{\sigma}_c^2$ 为对称正定协方差矩阵， $|\boldsymbol{\Sigma}_c|$ 表示 $\boldsymbol{\Sigma}_c$ 的行列式，将上

式代入对数似然函数可得 关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

$$LL(\boldsymbol{\theta}_c) = \sum_{\mathbf{x} \in D_c} \ln \left[\frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}_c|}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \right) \right]$$

令 $|D_c| = N$ 则对数似然函数可化为

$$LL(\boldsymbol{\theta}_c) = \sum_{i=1}^N \ln \left[\frac{1}{\sqrt{(2\pi)^d |\boldsymbol{\Sigma}_c|}} \exp \left(-\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right) \right]$$

$$= \sum_{i=1}^N \ln \left[\frac{1}{\sqrt{(2\pi)^d}} \cdot \frac{1}{\sqrt{|\boldsymbol{\Sigma}_c|}} \cdot \exp \left(-\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right) \right]$$

$$= \sum_{i=1}^N \left\{ \ln \frac{1}{\sqrt{(2\pi)^d}} + \ln \frac{1}{\sqrt{|\boldsymbol{\Sigma}_c|}} + \ln \left[\exp \left(-\frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right) \right] \right\}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

$$\begin{aligned} LL(\boldsymbol{\theta}_c) &= \sum_{i=1}^N \left\{ -\frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\boldsymbol{\Sigma}_c| - \frac{1}{2} (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right\} \\ &= -\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\boldsymbol{\Sigma}_c| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \end{aligned}$$

由于参数 $\boldsymbol{\theta}_c$ 的极大似然估计 $\hat{\boldsymbol{\theta}}_c$ 为

$$\hat{\boldsymbol{\theta}}_c = \arg \max_{\boldsymbol{\theta}_c} LL(\boldsymbol{\theta}_c)$$

所以接下来只需要求出使得对数似然函数 $LL(\boldsymbol{\theta}_c)$ 取到最大值的 $\hat{\boldsymbol{\mu}}_c$ 和 $\hat{\boldsymbol{\Sigma}}_c$ 也就求出了 $\hat{\boldsymbol{\theta}}_c$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

对 $LL(\boldsymbol{\theta}_c)$ 关于 $\boldsymbol{\mu}_c$ 求偏导

$$\begin{aligned}\frac{\partial LL(\boldsymbol{\theta}_c)}{\partial \boldsymbol{\mu}_c} &= \frac{\partial}{\partial \boldsymbol{\mu}_c} \left[-\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\boldsymbol{\Sigma}_c| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right] \\ &= \frac{\partial}{\partial \boldsymbol{\mu}_c} \left[-\frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right] \\ &= -\frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \boldsymbol{\mu}_c} [(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c)] \\ &= -\frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \boldsymbol{\mu}_c} [(\mathbf{x}_i^T - \boldsymbol{\mu}_c^T) \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c)]\end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

$$\begin{aligned}\frac{\partial LL(\theta_c)}{\partial \mu_c} &= -\frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \mu_c} [(\mathbf{x}_i^T - \mu_c^T)(\Sigma_c^{-1} \mathbf{x}_i - \Sigma_c^{-1} \mu_c)] \\ &= -\frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \mu_c} [\mathbf{x}_i^T \Sigma_c^{-1} \mathbf{x}_i - \mathbf{x}_i^T \Sigma_c^{-1} \mu_c - \mu_c^T \Sigma_c^{-1} \mathbf{x}_i + \mu_c^T \Sigma_c^{-1} \mu_c]\end{aligned}$$

由于 $\mathbf{x}_i^T \Sigma_c^{-1} \mu_c$ 的计算结果为标量，所以

$$\mathbf{x}_i^T \Sigma_c^{-1} \mu_c = (\mathbf{x}_i^T \Sigma_c^{-1} \mu_c)^T = \mu_c^T (\Sigma_c^{-1})^T \mathbf{x}_i = \mu_c^T (\Sigma_c^T)^{-1} \mathbf{x}_i = \mu_c^T \Sigma_c^{-1} \mathbf{x}_i$$

于是上式可以进一步化为

$$\frac{\partial LL(\theta_c)}{\partial \mu_c} = -\frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \mu_c} [\mathbf{x}_i^T \Sigma_c^{-1} \mathbf{x}_i - 2\mathbf{x}_i^T \Sigma_c^{-1} \mu_c + \mu_c^T \Sigma_c^{-1} \mu_c]$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

由矩阵微分公式 $\frac{\partial \mathbf{a}^T \mathbf{x}}{\partial \mathbf{x}} = \mathbf{a}$, $\frac{\partial \mathbf{x}^T \mathbf{B} \mathbf{x}}{\partial \mathbf{x}} = (\mathbf{B} + \mathbf{B}^T) \mathbf{x}$ 可得

$$\begin{aligned} \frac{\partial LL(\boldsymbol{\theta}_c)}{\partial \boldsymbol{\mu}_c} &= -\frac{1}{2} \sum_{i=1}^N [0 - (2\mathbf{x}_i^T \boldsymbol{\Sigma}_c^{-1})^T + (\boldsymbol{\Sigma}_c^{-1} + (\boldsymbol{\Sigma}_c^{-1})^T) \boldsymbol{\mu}_c] \\ &= -\frac{1}{2} \sum_{i=1}^N [- (2(\boldsymbol{\Sigma}_c^{-1})^T \mathbf{x}_i) + (\boldsymbol{\Sigma}_c^{-1} + (\boldsymbol{\Sigma}_c^{-1})^T) \boldsymbol{\mu}_c] \\ &= -\frac{1}{2} \sum_{i=1}^N [-(2\boldsymbol{\Sigma}_c^{-1} \mathbf{x}_i) + 2\boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c] \\ &= \sum_{i=1}^N \boldsymbol{\Sigma}_c^{-1} \mathbf{x}_i - N\boldsymbol{\Sigma}_c^{-1} \boldsymbol{\mu}_c \end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

令偏导数等于0可得

$$\frac{\partial LL(\theta_c)}{\partial \mu_c} = \sum_{i=1}^N \Sigma_c^{-1} \mathbf{x}_i - N \Sigma_c^{-1} \mu_c = 0$$

$$N \Sigma_c^{-1} \mu_c = \sum_{i=1}^N \Sigma_c^{-1} \mathbf{x}_i$$

$$N \Sigma_c^{-1} \mu_c = \Sigma_c^{-1} \sum_{i=1}^N \mathbf{x}_i$$

$$N \mu_c = \sum_{i=1}^N \mathbf{x}_i$$

$$\mu_c = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \Rightarrow \hat{\mu}_c = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i \quad \text{此即为式7.12}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

对 $LL(\boldsymbol{\theta}_c)$ 关于 $\boldsymbol{\Sigma}_c$ 求偏导

$$\begin{aligned}\frac{\partial LL(\boldsymbol{\theta}_c)}{\partial \boldsymbol{\Sigma}_c} &= \frac{\partial}{\partial \boldsymbol{\Sigma}_c} \left[-\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\boldsymbol{\Sigma}_c| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right] \\ &= \frac{\partial}{\partial \boldsymbol{\Sigma}_c} \left[-\frac{N}{2} \ln |\boldsymbol{\Sigma}_c| - \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) \right] \\ &= -\frac{N}{2} \cdot \frac{\partial}{\partial \boldsymbol{\Sigma}_c} [\ln |\boldsymbol{\Sigma}_c|] - \frac{1}{2} \sum_{i=1}^N \frac{\partial}{\partial \boldsymbol{\Sigma}_c} [(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c)]\end{aligned}$$

由矩阵微分公式 $\frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = |\mathbf{X}| \cdot (\mathbf{X}^{-1})^T$, $\frac{\partial \mathbf{a}^T \mathbf{X}^{-1} \mathbf{b}}{\partial \mathbf{X}} = -\mathbf{X}^{-T} \mathbf{a} \mathbf{b}^T \mathbf{X}^{-T}$ 可得

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

$$\begin{aligned}\frac{\partial LL(\boldsymbol{\theta}_c)}{\partial \boldsymbol{\Sigma}_c} &= -\frac{N}{2} \cdot \frac{1}{|\boldsymbol{\Sigma}_c|} \cdot |\boldsymbol{\Sigma}_c| \cdot (\boldsymbol{\Sigma}_c^{-1})^T - \frac{1}{2} \sum_{i=1}^N \left[-\boldsymbol{\Sigma}_c^{-T} (\mathbf{x}_i - \boldsymbol{\mu}_c) (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-T} \right] \\ &= -\frac{N}{2} \cdot (\boldsymbol{\Sigma}_c^{-1})^T - \frac{1}{2} \sum_{i=1}^N \left[-\boldsymbol{\Sigma}_c^{-T} (\mathbf{x}_i - \boldsymbol{\mu}_c) (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-T} \right] \\ &= -\frac{N}{2} \boldsymbol{\Sigma}_c^{-1} + \frac{1}{2} \sum_{i=1}^N \left[\boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} \right]\end{aligned}$$

令偏导数等于0可得

$$\frac{\partial LL(\boldsymbol{\theta}_c)}{\partial \boldsymbol{\Sigma}_c} = -\frac{N}{2} \boldsymbol{\Sigma}_c^{-1} + \frac{1}{2} \sum_{i=1}^N \left[\boldsymbol{\Sigma}_c^{-1} (\mathbf{x}_i - \boldsymbol{\mu}_c) (\mathbf{x}_i - \boldsymbol{\mu}_c)^T \boldsymbol{\Sigma}_c^{-1} \right] = 0$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

多元正态分布参数的极大似然估计



deepshare.net

深度之眼

Maximum Likelihood Estimation of Multivariate Normal Distribution Parameters

$$-\frac{N}{2}\Sigma_c^{-1} = -\frac{1}{2} \sum_{i=1}^N [\Sigma_c^{-1}(\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \Sigma_c^{-1}]$$

$$N\Sigma_c^{-1} = \sum_{i=1}^N [\Sigma_c^{-1}(\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \Sigma_c^{-1}]$$

$$N\Sigma_c^{-1} = \Sigma_c^{-1} \left[\sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \right] \Sigma_c^{-1}$$

$$N = \Sigma_c^{-1} \left[\sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \right]$$

$$\Sigma_c = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \Rightarrow \hat{\Sigma}_c = \frac{1}{N} \sum_{i=1}^N (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^T \quad \text{此即为式7.13}$$

最值点证明：《多元正态分布参数的估计和数据的清洁与变换》 (http://staff.ustc.edu.cn/~zwp/teach/MVA/Lec5_slides.pdf)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



deepshare.net

深度之眼

已知最小化分类错误率的贝叶斯最优分类器为

$$h^*(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c|\mathbf{x})$$

又由贝叶斯定理可知

$$P(c|\mathbf{x}) = \frac{P(\mathbf{x}, c)}{P(\mathbf{x})} = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})}$$

所以

$$h^*(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \arg \max_{c \in \mathcal{Y}} P(c)P(\mathbf{x}|c)$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



deepshare.net

深度之眼

已知属性条件独立性假设为

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c) = \prod_{i=1}^d P(x_i|c)$$

所以

$$h^*(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i|c)$$

此即为朴素贝叶斯分类器的表达式

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



对于 $P(c)$

它表示的是样本空间中各类样本所占的比例，根据大数定律，当训练集包含充足的独立同分布样本时， $P(c)$ 可通过各类样本出现的频率来进行估计，也即

$$P(c) = \frac{|D_c|}{|D|}$$

其中， D 表示训练集， $|D|$ 表示 D 中的样本个数， D_c 表示训练集 D 中第 c 类样本组成的集合， $|D_c|$ 表示集合 D_c 中的样本个数。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



deepshare.net

深度之眼

对于 $P(x_i|c)$

若样本的第i个属性 x_i 取值为连续值:

我们假设该属性的取值服从正态分布, 也即

$$P(x_i|c) \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2) \Rightarrow P(x_i|c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp\left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2}\right)$$

其中正态分布的参数可以用极大似然估计法推得: $\mu_{c,i}$ 和 $\sigma_{c,i}^2$ 即为第c类样本在第i个属性上取值的均值和方差

关注公众号深度之眼, 后台回复资料, 获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



对于 $P(x_i|c)$

若样本的第*i*个属性 x_i 取值为离散值:

同样根据极大似然估计法, 我们用其频率值作为其概率值的估计值, 也即

$$P(x_i|c) = \frac{|D_{c,x_i}|}{|D_c|}$$

其中, D_{c,x_i} 表示 D_c 中在第*i*个属性上取值为 x_i 的样本组成的集合。

朴素贝叶斯分类器

Naive Bayes classifier



deepshare.net

深度之眼

例：现将一枚6面骰子抛掷10次，抛掷出的点数分别为2、3、2、5、4、6、1、3、4、2，试基于此抛掷结果估计这枚骰子抛掷出各个点数的概率。

[解]：设这枚骰子抛掷出点数*i*的概率为 P_i ，根据极大似然估计法可以写出似然函数为

$$L(\theta) = P_1 \times P_2^3 \times P_3^2 \times P_4^2 \times P_5 \times P_6$$

其对数似然函数即为

$$LL(\theta) = \ln L(\theta) = \ln(P_1 \times P_2^3 \times P_3^2 \times P_4^2 \times P_5 \times P_6)$$

$$= \ln P_1 + 3 \ln P_2 + 2 \ln P_3 + 2 \ln P_4 + \ln P_5 + \ln P_6$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



由于 P_i 之间满足如下约束

$$P_1 + P_2 + P_3 + P_4 + P_5 + P_6 = 1$$

所以此时最大化对数似然函数属于带约束的最优化问题，也即

$$\max \quad LL(\theta) = \ln P_1 + 3 \ln P_2 + 2 \ln P_3 + 2 \ln P_4 + \ln P_5 + \ln P_6$$

$$s.t. \quad P_1 + P_2 + P_3 + P_4 + P_5 + P_6 = 1$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器



Naive Bayes classifier

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

定理：对于一个优化问题

$$\begin{aligned} \min \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & g_i(\mathbf{x}) \leq 0 \quad (i = 1, \dots, n) \\ & h_j(\mathbf{x}) = 0 \quad (j = 1, \dots, m) \end{aligned}$$

若 $f(\mathbf{x}), g_i(\mathbf{x}), h_j(\mathbf{x})$ 一阶连续可微，并且 $f(\mathbf{x}), g_i(\mathbf{x})$ 是凸函数， $h_j(\mathbf{x})$ 是线性函数，那么满足如下KKT条件的点 \mathbf{x}^* 一定是优化问题的最优解。

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}^*, \boldsymbol{\mu}^*, \boldsymbol{\lambda}^*) = \nabla f(\mathbf{x}^*) + \sum_{i=1}^n \mu_i^* \nabla g_i(\mathbf{x}^*) + \sum_{j=1}^m \lambda_j^* \nabla h_j(\mathbf{x}^*) = 0 \\ h_j(\mathbf{x}^*) = 0 \\ g_i(\mathbf{x}^*) \leq 0 \\ \mu_i^* \geq 0 \\ \mu_i^* g_i(\mathbf{x}^*) = 0 \end{cases}$$

参考文献:王燕军, 梁治安. 最优化基础理论与方法[M]. 复旦大学出版社, 2011.

朴素贝叶斯分类器



Naive Bayes classifier

由拉格朗日乘子法可得拉格拉格朗日函数为

$$\mathcal{L}(\theta, \lambda) = \ln P_1 + 3 \ln P_2 + 2 \ln P_3 + 2 \ln P_4 + \ln P_5 + \ln P_6 + \lambda(P_1 + P_2 + P_3 + P_4 + P_5 + P_6 - 1)$$

对拉格朗日函数 $\mathcal{L}(\theta)$ 分别关于 P_i 求偏导，然后令其等于0可得

$$\begin{aligned}\frac{\partial \mathcal{L}(\theta, \lambda)}{\partial P_1} &= \frac{\partial}{\partial P_1} [\ln P_1 + 3 \ln P_2 + 2 \ln P_3 + 2 \ln P_4 + \ln P_5 + \ln P_6 + \lambda(P_1 + P_2 + P_3 + P_4 + P_5 + P_6 - 1)] = 0 \\ &= \frac{\partial}{\partial P_1} (\ln P_1 + \lambda P_1) = 0 \\ &= \frac{1}{P_1} + \lambda = 0 \\ \Rightarrow \lambda &= -\frac{1}{P_1}\end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

朴素贝叶斯分类器

Naive Bayes classifier



deepshare.net

深度之眼

同理可求得：

$$\lambda = -\frac{1}{P_1} = -\frac{3}{P_2} = -\frac{2}{P_3} = -\frac{2}{P_4} = -\frac{1}{P_5} = -\frac{1}{P_6}$$

又因为

$$P_1 + P_2 + P_3 + P_4 + P_5 + P_6 = 1$$

所以最终解得

$$P_1 = \frac{1}{10}, P_2 = \frac{3}{10}, P_3 = \frac{2}{10}, P_4 = \frac{2}{10}, P_5 = \frac{1}{10}, P_6 = \frac{1}{10}$$

此时抛掷出各个点数的概率值与其频率值相等。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

—— 结 语 ——

在这次课程中，我们学习了西瓜书

朴素贝叶斯的公式推导

那么在下次课程中，我们将会学习西瓜书

神经网络的公式推导



关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

联系我们：

电话：18001992849

邮箱：service@deepshare.net

QQ：2677693114



公众号



客服微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料