



法律声明

本课件包括演示文稿、示例、代码、题库、视频和声音等内容，深度之眼和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

课程详情请咨询

- 微信公众号：深度之眼
- 客服微信号：deepshare0920



公众号



微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

西瓜书公式推导

导师: Sm1les (Datawhale南瓜书项目负责人)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法公式推导

Derivation of Expectation-maximization algorithm

本节大纲



Outline

先修内容：西瓜书7.6、统计学习方法9.1

1. EM算法的引入

- 为什么需要EM算法

2. EM算法的例子

- 三硬币模型

3. EM算法的导出

- Jensen（琴生）不等式
- EM算法的推导

4. EM算法求解例子

- 用EM算法求解三硬币模型

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的引入

Introduction of EM algorithm



deepshare.net

深度之眼

为什么需要EM算法：

概率模型有时既含有观测变量，又含有隐变量或者潜在变量。如果概率模型的变量都是观测变量，那么给定数据，可以直接用极大似然估计法，或者贝叶斯估计法估计模型参数。但是，当模型含有隐变量时，就不能简单地使用这些估计方法。EM算法就是含有隐变量的概率模型参数的极大似然估计法。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的例子



Example of EM algorithm

《统计学习方法》例9.1（三硬币模型）：

假设有3枚硬币，分别记作A，B，C。这些硬币正面出现的概率分别是 π ， p 和 q 。进行如下掷硬币试验：先掷硬币A，根据其结果选出硬币B或硬币C，正面选硬币B，反面选硬币C；然后掷选出的硬币，掷硬币的结果，出现正面记作1，出现反面记作0；独立地重复 n 次实验（这里， $n=10$ ），观测结果如下：

1, 1, 0, 1, 0, 0, 1, 0, 1, 1

假设只能观测到掷硬币的结果，不能观测掷硬币的过程。问如何估计三硬币正面出现的概率，即三硬币模型的参数。

《统计学习方法》例9.1（三硬币模型）：

假设有3枚硬币，分别记作A，B，C。这些硬币正面出现的概率分别是 π ， p 和 q 。进行如下掷硬币试验：先掷硬币A，根据其结果选出硬币B或硬币C，正面选硬币B，反面选硬币C；然后掷选出的硬币，掷硬币的结果，出现正面记作1，出现反面记作0；独立地重复 n 次实验（这里， $n=10$ ），观测结果如下：

1, 1, 0, 1, 0, 0, 1, 0, 1, 1

假设只能观测到掷硬币的结果，不能观测掷硬币的过程。问如何估计三硬币正面出现的概率，即三硬币模型的参数。

解：对每一次试验可以进行如下建模

$$\begin{aligned} P(y|\theta) &= \sum_z P(y, z|\theta) = \sum_z P(z|\theta)P(y|z, \theta) \\ &= P(z=1|\theta)P(y|z=1, \theta) + P(z=0|\theta)P(y|z=0, \theta) \\ &= \begin{cases} \pi p + (1-\pi)q, & \text{if } y=1; \\ \pi(1-p) + (1-\pi)(1-q), & \text{if } y=0; \end{cases} \\ &= \pi p^y (1-p)^{1-y} + (1-\pi)q^y (1-q)^{1-y} \end{aligned}$$

其中，随机变量 y 是观测变量，表示一次试验观测的结果是1或0；随机变量 z 是隐变量，表示未观测到的掷硬币A的结果；

$\theta=(\pi, p, q)$ 是模型参数。将观测数据表示为 $Y=(Y_1, Y_2, \dots, Y_n)^T$ ，未观测数据表示为 $Z=(Z_1, Z_2, \dots, Z_n)^T$

则观测数据的似然函数为：

$$P(Y|\theta) = \sum_Z P(Z|\theta)P(Y|Z, \theta) = \prod_{j=1}^n P(y_j|\theta) = \prod_{j=1}^n [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi)q^{y_j} (1-q)^{1-y_j}]$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

$$P(Y|\theta) = \prod_{j=1}^n [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi) q^{y_j} (1-q)^{1-y_j}]$$

考虑求模型参数 $\theta=(\pi,p,q)$ 的极大似然估计，即使用对数似然函数来进行参数估计可得：

$$\hat{\theta} = \arg \max_{\theta} \ln P(Y|\theta)$$

$$= \arg \max_{\theta} \ln \prod_{j=1}^n [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi) q^{y_j} (1-q)^{1-y_j}]$$

$$= \arg \max_{\theta} \sum_{j=1}^n \ln [\pi p^{y_j} (1-p)^{1-y_j} + (1-\pi) q^{y_j} (1-q)^{1-y_j}]$$

上式没有解析解，也就是没办法直接解出 π,p,q 恰好等于某个常数，只能用迭代的方法来进行求解。

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

—— 结 语 ——

在这次课程中，我们学习了

EM算法的引入和例子

那么在下次课程中，我们将会学习

EM算法的导出



关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

联系我们：

电话：18001992849

邮箱：service@deepshare.net

QQ：2677693114



公众号



客服微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料