



法律声明

本课件包括演示文稿、示例、代码、题库、视频和声音等内容，深度之眼和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

课程详情请咨询

- 微信公众号：深度之眼
- 客服微信号：deepshare0920



公众号



微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

西瓜书公式推导

导师: Sm1les (Datawhale南瓜书项目负责人)

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法公式推导

Derivation of Expectation-maximization algorithm

本节大纲

Outline

先修内容：西瓜书7.6、统计学习方法9.1

1. EM算法的引入

- 为什么需要EM算法

2. EM算法的例子

- 三硬币模型

3. EM算法的导出

- Jensen（琴生）不等式
- EM算法的推导

4. EM算法求解例子

- 用EM算法求解三硬币模型

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的导出



Derivation of EM algorithm 关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

Jensen（琴生）不等式：

若 f 是凸函数，则：

$$f(tx_1 + (1-t)x_2) \leq tf(x_1) + (1-t)f(x_2)$$

其中， $t \in [0,1]$ 同理，若 f 是凹函数，则只需将上式中的 换成 即可。

将上式中的 t 推广到 n 个同样成立，也即：

$$f(t_1x_1 + t_2x_2 + \dots + t_nx_n) \leq t_1f(x_1) + t_2f(x_2) + \dots + t_nf(x_n)$$

其中， $t_1, t_2, \dots, t_n \in [0,1], t_1 + t_2 + \dots + t_n = 1$ 概率论中常以以下形式出现：

$$\varphi(E[X]) \leq E[\varphi(X)]$$

其中， X 是随机变量， φ 是凸函数， $E[X]$ 表示 X 的期望。

EM算法的导出



Derivation of EM algorithm

我们面对一个含有隐变量的概率模型，目标是极大化观测数据Y关于参数 θ 的对数似然函数，即极大化：

$$L(\theta) = \ln P(Y|\theta) = \ln \sum_Z P(Y, Z|\theta) = \ln \left(\sum_Z P(Y|Z, \theta) P(Z|\theta) \right)$$

注意到这一极大化的主要困难是上式中有未观测数据Z并有包含和（Z为离散型时）或者积分（Z为连续型时）的对数。EM算法采用的是通过迭代逐步近似极大化 $L(\theta)$ 。假设在第i次迭代后 θ 的估计值是 $\theta^{(i)}$ ，我们希望新的估计值 θ 能使 $L(\theta)$ 增加，即 $L(\theta) > L(\theta^{(i)})$ 并逐步达到极大值。为此，我们考虑两者的差：

EM算法的导出

Derivation of EM algorithm

$$\begin{aligned} L(\theta) - L(\theta^{(i)}) &= \ln \left(\sum_Z P(Y|Z, \theta) P(Z|\theta) \right) - \ln P(Y|\theta^{(i)}) \\ &= \ln \left(\sum_Z P(Z|Y, \theta^{(i)}) \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} \right) - \ln P(Y|\theta^{(i)}) \end{aligned}$$

套用琴生不等式可得：

$$\begin{aligned} &\geq \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \ln P(Y|\theta^{(i)}) \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta) P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - 1 \cdot \ln P(Y|\theta^{(i)}) \end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的导出

Derivation of EM algorithm

$$\begin{aligned} L(\theta) - L(\theta^{(i)}) &\geq \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \sum_Z P(Z|Y, \theta^{(i)}) \cdot \ln P(Y|\theta^{(i)}) \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \left(\ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})} - \ln P(Y|\theta^{(i)}) \right) \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})} \\ L(\theta) &\geq L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})} \end{aligned}$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的导出

Derivation of EM algorithm

$$\text{令 } B(\theta, \theta^{(i)}) = L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})}$$

则
$$L(\theta) \geq B(\theta, \theta^{(i)})$$

即函数 $B(\theta, \theta^{(i)})$ 是 $L(\theta)$ 的一个下界，此时若设 $\theta^{(i+1)}$ 使得 $B(\theta, \theta^{(i)})$ 达到极大，也即

$$B(\theta^{(i+1)}, \theta^{(i)}) \geq B(\theta^{(i)}, \theta^{(i)})$$

由于 $B(\theta^{(i)}, \theta^{(i)}) = L(\theta^{(i)})$ ，所以可以进一步推得：

$$L(\theta^{(i+1)}) \geq B(\theta^{(i+1)}, \theta^{(i)}) \geq B(\theta^{(i)}, \theta^{(i)}) = L(\theta^{(i)})$$

$$L(\theta^{(i+1)}) \geq L(\theta^{(i)})$$

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

EM算法的导出



Derivation of EM algorithm 关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料

因此，任何可以使 $B(\theta, \theta^{(i)})$ 增大的 θ ，也可以使 $L(\theta)$ 增大，于是问题就转化为了求解能使得 $B(\theta, \theta^{(i)})$ 达到极大的 $\theta^{(i+1)}$ ，即

$$\begin{aligned}\theta^{(i+1)} &= \arg \max_{\theta} B(\theta, \theta^{(i)}) \\ &= \arg \max_{\theta} \left(L(\theta^{(i)}) + \sum_Z P(Z|Y, \theta^{(i)}) \ln \frac{P(Y|Z, \theta)P(Z|\theta)}{P(Z|Y, \theta^{(i)})P(Y|\theta^{(i)})} \right) \\ &= \arg \max_{\theta} \left(\sum_Z P(Z|Y, \theta^{(i)}) \ln (P(Y|Z, \theta)P(Z|\theta)) \right) \\ &= \arg \max_{\theta} \left(\sum_Z P(Z|Y, \theta^{(i)}) \ln P(Y, Z|\theta) \right) \\ &= \arg \max_{\theta} Q(\theta, \theta^{(i)})\end{aligned}$$

EM算法的导出



Derivation of EM algorithm

到此即完成了EM算法的一次迭代，求出的 $\theta^{(i+1)}$ 作为下一次迭代的初始 $\theta^{(i)}$ 。综上所述可以总结出EM算法的“E步”和“M步”分别为：

E步：计算完全数据的对数似然函数 $\ln P(Y, Z|\theta)$ 关于在给定观测数据Y和当前参数 θ 下对未观测数据Z的条件概率分布 $P(Z|Y, \theta^{(i)})$ 的期望，也即Q函数：

$$Q(\theta, \theta^{(i)}) = E_Z[\ln P(Y, Z|\theta)|Y, \theta^{(i)}] = \sum_Z P(Z|Y, \theta^{(i)}) \ln P(Y, Z|\theta)$$

M步：求使得Q函数到达极大的 $\theta^{(i+1)}$ 。

—— 结 语 ——

在这次课程中，我们学习了

EM算法的导出

那么在下次课程中，我们将会学习

EM算法求解例子



关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料



deepshare.net

深度之眼

联系我们：

电话：18001992849

邮箱：service@deepshare.net

QQ：2677693114



公众号



客服微信

关注公众号深度之眼，后台回复资料，获取AI必学书籍及完整实战学习资料